

视听信息系统导论 第四次作业

BobAnkh

December 2020

1. 线性对数几率回归中假设 $f(x) = w^T x + b$ ，设计一种数据处理方案使得参数 b 可以不用出现

可以在向量 x 的末尾增加一个取值全为 1 的维度；或者也可以将所有的数据都减去某一个特定的数据，如 $x_k - x_0$ 。

2. 用牛顿法求解无约束优化问题，目标函数为

$$f(x) = \log(e^x + e^{-x})$$

分别以初值 $x^{(0)}=1$ 和 $x^{(0)} = 1.1$ ，写出前五步迭代过程，令迭代步长 $=1$ 。

目标函数为 $f(x) = \log(e^x + e^{-x})$ ，则可以得到其一阶导和二阶导为：

$$f'(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

$$f''(x) = \frac{4}{(e^x + e^{-x})^2}$$

由此进行迭代：

1. $x^{(0)} = 1$ 时

$x^{(0)}$	1
$x^{(1)}$	-0.8134
$x^{(2)}$	0.4094
$x^{(3)}$	-0.04730
$x^{(4)}$	7.060e-5
$x^{(5)}$	-2.347e-13

2. $x^{(0)} = 1.1$ 时

$x^{(0)}$	1.1
$x^{(1)}$	-1.129
$x^{(2)}$	1.234
$x^{(3)}$	-1.695
$x^{(4)}$	5.715
$x^{(5)}$	-23021

3. 总变分 (total variation) 是视听处理领域一种经典的去除噪声的方法。

假设输入的被噪声污染的信号用列向量表示为 $x \in R^n$, 用 x_i 表示 x 的第 i 个元素。则去噪之后的信号 $\hat{x} \in R^n$ 通过下面的无约束优化问题求得, 其中 $\epsilon > 0, \mu > 0$ 是两个常数。

$$\text{minimize } f(x) = \|x - \hat{x}\|_2^2 + \mu \sum_{i=1}^{n-1} \sqrt{\epsilon^2 + (x_{i+1} - x_i)^2} - \epsilon$$

1) 若采用梯度下降法求解该问题, 写出下降方向 Δx 的数学表达式 (明确给出 Δx 每个元素的表达式);

2) 若采用牛顿法求解该问题, 写出计算下降方向 Δx 的线性方程组的数学表达式 (明确给出系数矩阵每个元素的表达式);

3) 分析求解问题 (2) 中的线性方程组的时间复杂度。

(1) 在梯度下降法中, $\Delta x = -\nabla f(x)$, 故有:

$$\frac{\partial f}{\partial x_1} = 2(x_1 - \hat{x}_1) + \mu \frac{x_1 - x_2}{\sqrt{\epsilon^2 + (x_2 - x_1)^2}}$$

$$\frac{\partial f}{\partial x_i} = 2(x_i - \hat{x}_i) + \mu \frac{x_i - x_{i+1}}{\sqrt{\epsilon^2 + (x_{i+1} - x_i)^2}} + \mu \frac{x_i - x_{i-1}}{\sqrt{\epsilon^2 + (x_i - x_{i-1})^2}}, \quad \text{for } 1 < i < n$$

$$\frac{\partial f}{\partial x_n} = 2(x_n - \hat{x}_n) + \mu \frac{x_n - x_{n-1}}{\sqrt{\epsilon^2 + (x_n - x_{n-1})^2}}$$

(2) 在牛顿法中, $\nabla^2 f(x) \Delta x = -\nabla f(x)$, 故 Δx 可通过解此方程求得。 $\nabla f(x)$ 上一问中已经计算过, 本问中计算海森矩阵 $\nabla^2 f(x)$ 即可:

$\nabla^2 f(x)$ 首行为 $\frac{\partial^2 f(x)}{\partial x_1 \partial x_i}$, 故可知该行第一个元素为 $2 + \mu \epsilon^2 (\epsilon^2 + (x_2 - x_1)^2)^{-\frac{3}{2}}$, 第二个元素为 $-\mu \epsilon^2 (\epsilon^2 + (x_2 - x_1)^2)^{-\frac{3}{2}}$, 其余元素为 0

$\nabla^2 f(x)$ 中间第 i 行 ($1 < i < n$) 为 $\frac{\partial^2 f(x)}{\partial x_i \partial x_j}$ ($1 \leq j \leq n$), 故可知对于这第 i 行, 第 $i-1$ 个元素为 $-\mu \epsilon^2 (\epsilon^2 + (x_i - x_{i-1})^2)^{-\frac{3}{2}}$, 第 i 个元素为 $2 + \mu \epsilon^2 (\epsilon^2 + (x_{i+1} - x_i)^2)^{-\frac{3}{2}} + \mu \epsilon^2 (\epsilon^2 + (x_i - x_{i-1})^2)^{-\frac{3}{2}}$, 第 $i+1$ 个元素为 $-\mu \epsilon^2 (\epsilon^2 + (x_{i+1} - x_i)^2)^{-\frac{3}{2}}$, 其余元素为 0

$\nabla^2 f(x)$ 最后一行 (即第 n 行) 为 $\frac{\partial^2 f(x)}{\partial x_1 \partial x_i}$, 故可知该行第 $n-1$ 个元素为 $-\mu \epsilon^2 (\epsilon^2 + (x_n - x_{n-1})^2)^{-\frac{3}{2}}$, 第 n 个元素为 $2 + \mu \epsilon^2 (\epsilon^2 + (x_n - x_{n-1})^2)^{-\frac{3}{2}}$, 其余元素为 0

- (3) 由 (2) 中分析过程可知, 对于本问题中的海森矩阵, 除首尾两行各 2 个元素非 0 外, 每行只有两个元素非 0, 故可直接使用高斯消元法求解, 时间复杂度是 $O(n)$ 级别的。

4. x 为二维非负向量, 证明:

双曲集合 $\{x \in R_+^2 | x_1 x_2 \geq 1\}$ 是凸集合

假设 (x_1, x_2) 和 (y_1, y_2) 都属于该双曲集合, 那么对于 $\theta \in [0, 1]$, 有:

$$z_1 = \theta x_1 + (1 - \theta)y_1, z_2 = \theta x_2 + (1 - \theta)y_2$$

若 $x_1 \geq y_1$ 且 $x_2 \geq y_2$, 那么显然有 $z_1 \geq y_1, z_2 \geq y_2$, 则可得 $z_1 z_2 \geq y_1 y_2 \geq 1$

若 $y_1 \geq x_1$ 且 $y_2 \geq x_2$, 那么显然有 $z_1 \geq x_1, z_2 \geq x_2$, 则可得 $z_1 z_2 \geq x_1 x_2 \geq 1$

而另外的两种情况必然会有 $(y_1 - x_1)(y_2 - x_2) < 0$, 则可求得:

$$\begin{aligned} z_1 z_2 &= (\theta x_1 + (1 - \theta)y_1)(\theta x_2 + (1 - \theta)y_2) \\ &= \theta^2 x_1 x_2 + (1 - \theta)^2 y_1 y_2 + \theta(1 - \theta)(y_1 x_2 + x_1 y_2) \\ &= \theta x_1 x_2 + (1 - \theta)y_1 y_2 - \theta(1 - \theta)(y_1 - x_1)(y_2 - x_2) \\ &\geq 1 \end{aligned}$$

综上, 可以证明该双曲集合是凸集合。

5. 已知 R^{m+n} 上的两个凸集合 S_1 和 S_2

证明它们的部分和集合 S 也是凸集合: $S = \{(x, y_1 + y_2) | x \in R^m, y_1, y_2 \in R^n, (x, y_1) \in S_1, (x, y_2) \in S_2\}$

取 $(\bar{x}, \bar{y}_1) \in S_1, (\bar{x}, \bar{y}_2) \in S_2, (\hat{x}, \hat{y}_1) \in S_1, (\hat{x}, \hat{y}_2) \in S_2$, 则

$$(\bar{x}, \bar{y}_1 + \bar{y}_2) \in S, (\hat{x}, \hat{y}_1 + \hat{y}_2) \in S$$

对于 $\theta \in [0, 1]$, 有 $\theta(\bar{x}, \bar{y}_1 + \bar{y}_2) + (1 - \theta)(\hat{x}, \hat{y}_1 + \hat{y}_2) = (\theta\bar{x} + (1 - \theta)\hat{x}, (\theta\bar{y}_1 + (1 - \theta)\hat{y}_1) + (\theta\bar{y}_2 + (1 - \theta)\hat{y}_2))$

而已知 S_1 和 S_2 都是凸集, 故有 $(\theta\bar{x} + (1 - \theta)\hat{x}, \theta\bar{y}_1 + (1 - \theta)\hat{y}_1) \in S_1, (\theta\bar{x} + (1 - \theta)\hat{x}, \theta\bar{y}_2 + (1 - \theta)\hat{y}_2) \in S_2$

所以可以得到 $(\theta\bar{x} + (1 - \theta)\hat{x}, (\theta\bar{y}_1 + (1 - \theta)\hat{y}_1) + (\theta\bar{y}_2 + (1 - \theta)\hat{y}_2)) \in S$, 由此得证。

6. 连续函数 $f: R^n \rightarrow R$

证明 f 为凸函数当且仅当对任意 $x, y \in R^n$, 下式成立: $\int_0^1 f(x + \lambda(y - x))d\lambda \leq \frac{f(x) + f(y)}{2}$

先证 f 为凸函数时, 该式成立:

根据 Jensen's 不等式, 对于 $\forall \lambda \in [0, 1]$ 有

$$f(\lambda y + (1 - \lambda)x) \leq \lambda f(y) + (1 - \lambda)f(x)$$

两边在 $[0, 1]$ 上积分可得:

$$\int_0^1 f(\lambda y + (1 - \lambda)x) d\lambda \leq \int_0^1 (\lambda f(y) + (1 - \lambda)f(x)) d\lambda = \frac{f(x) + f(y)}{2}$$

此即 $\int_0^1 f(x + \lambda(y - x)) d\lambda \leq \frac{f(x) + f(y)}{2}$

再证 f 不是凸函数时, 该式一定不成立:

若 f 不是凸函数, 则 Jensen's 不等式不成立, 即 $\exists x, y, \lambda_0 \in (0, 1)$, 使得 $f(\lambda_0 x + (1 - \lambda_0)y) > \lambda_0 f(x) + (1 - \lambda_0)f(y)$

考虑连续函数 $F(\lambda) = f(\lambda x + (1 - \lambda)y) - \lambda f(x) - (1 - \lambda)f(y)$, 显然仅当 $\lambda = 0$ 或 $\lambda = 1$ 时, $F(\lambda) = 0$, 对于 λ_0 , 有 $F(\lambda_0) > 0$

若记 α, β 分别为 λ_0 左侧和右侧最近的零点, 则在区间 (α, β) 上, 有

$$f(\lambda x + (1 - \lambda)y) > \lambda f(x) + (1 - \lambda)f(y)$$

令 $u = \alpha x + (1 - \alpha)y$, $v = \beta x + (1 - \beta)y$, 则对于 $\lambda \in (0, 1)$ 有

$$f(\lambda u + (1 - \lambda)v) > \lambda f(u) + (1 - \lambda)f(v)$$

两边在 $[0, 1]$ 上积分可得:

$$\int_0^1 f(v + \lambda(u - v)) d\lambda > \int_0^1 (\lambda f(u) + (1 - \lambda)f(v)) d\lambda = \frac{f(u) + f(v)}{2}$$

这与题设条件相矛盾, 由此可以说明在 f 不是凸函数时, 该式一定不成立。

综上所述, 当且仅当 f 为凸函数是, 该式成立。

7. 两个元素取值为正数的向量 x, y 满足:

$x, y \in R_{++}^n$, 其相对熵定义如下, 其中 x_k, y_k 分别是向量 x, y 的第 k 个元素, \log 表示自然对数:

$$\sum_{k=1}^n x_k \log\left(\frac{x_k}{y_k}\right)$$

1) 证明相对熵是变量 x, y 的凸函数;

2) 假设 y 是一个给定的常数向量, 定义如下的等式约束优化问题, 其中 $A \in R^{m \times n}$, $b \in R^m$:

$$\begin{aligned} & \text{minimize} \quad \sum_{k=1}^n x_k \log\left(\frac{x_k}{y_k}\right) \\ & \text{subject to} \quad Ax = b \\ & \quad \quad \quad \sum_{k=1}^n x_k = 1 \end{aligned}$$

证明该优化问题的对偶问题是如下形式，其中 a_k 是矩阵 A 的第 k 列：

$$\text{minimize } b^T z + \log \sum_{k=1}^n y_k e^{-a_k^T z}$$

1. 先证明相对熵是 x 的凸函数。记相对熵为 $f(x, y) = \sum_{k=1}^n x_k \log \frac{x_k}{y_k}$

令 $g(x) = x \log \frac{x}{y}$ ，其中 y 此时是常数参量，则有 $g''(x) = \frac{1}{x}$ ，显然在 $x > 0$ 时， $g(x)$ 是凸函数

对于 $\forall \theta \in [0, 1]$ 有

$$\begin{aligned} \theta f(x_1, y) + (1 - \theta)f(x_2, y) &= \theta \sum_{k=1}^n x_{1k} \log \frac{x_{1k}}{y_k} + (1 - \theta) \sum_{k=1}^n x_{2k} \log \frac{x_{2k}}{y_k} \\ &= \sum_{k=1}^n (\theta x_{1k} \log \frac{x_{1k}}{y_k} + (1 - \theta)x_{2k} \log \frac{x_{2k}}{y_k}) \\ &\geq \sum_{k=1}^n [\theta x_{1k} + (1 - \theta)x_{2k}] \log \frac{[\theta x_{1k} + (1 - \theta)x_{2k}]}{y_k} \\ &= f(\theta x_1 + (1 - \theta)x_2, y) \end{aligned}$$

由此可说明 $f(x, y)$ 是 x 的凸函数。

接下来证明相对熵是 y 的凸函数。此时可以将相对熵写作如下形式：

$$f(x, y) = \sum_{k=1}^n x_k \log \frac{x_k}{y_k} = \sum_{k=1}^n x_k \log x_k - \sum_{k=1}^n x_k \log y_k$$

令 $h(y) = -x \log y$ ，其中 x 此时是常数参量，则有 $h''(y) = \frac{1}{y^2}$ ，显然在 $y > 0$ 时， $h(x)$ 是凸函数

对于 $\forall \theta \in [0, 1]$ 有

$$\begin{aligned} \theta f(x, y_1) + (1 - \theta)f(x, y_2) &= \sum_{k=1}^n (x_k \log x_k - \theta x_k \log y_{1k} - (1 - \theta)x_k \log y_{2k}) \\ &\geq \sum_{k=1}^n (x_k \log x_k - x_k \log(\theta y_{1k} + (1 - \theta)y_{2k})) \\ &= f(x, \theta y_1 + (1 - \theta)y_2) \end{aligned}$$

由此可说明 $f(x, y)$ 是 y 的凸函数。

2. 对于等式约束优化问题，有 $L(x, \lambda, \mu) = \sum_{k=1}^n x_k \log \frac{x_k}{y_k} + \lambda^T (Ax - b) + \mu(\sum_{k=1}^n x_k - 1)$

令 $\frac{\partial L}{\partial x_k} = 0$ ， $\frac{\partial L}{\partial \lambda} = 0$ ， $\frac{\partial L}{\partial \mu} = 0$ ，则有

$$\log \frac{x_k}{y_k} = -1 - \mu - \lambda^T a_k \quad (1)$$

$$Ax - b = 0 \quad (2)$$

$$\sum_{k=1}^n x_k - 1 = 0 \quad (3)$$

将 (1)(2)(3) 三式代入 $L(x, \lambda, \mu)$ 可得原问题的对偶形式:

$$\min_x \sum_{k=1}^n x_k \log \frac{x_k}{y_k} \iff \max_{\lambda, \mu} g(\lambda, \mu)$$

其中, $g(\lambda, \mu)$ 满足:

$$\begin{aligned} g(\lambda, \mu) &= L(x, \lambda, \mu) = \sum_{k=1}^n x_k (-1 - \mu - \lambda^T a_k) \\ &= - \sum_{k=1}^n x_k a_k^T \lambda - (1 + \mu) \\ &= -(AX)^T \lambda - (1 + \mu) \end{aligned}$$

又由 (1) 知: $x_k = y_k e^{-1-\mu-\lambda^T a_k}$, 由此可得 $\mu + 1 = \log \sum_{k=1}^n y_k e^{-a_k^T \lambda}$

故 $g(\lambda, \mu) = -b^T \lambda - \log \sum_{k=1}^n y_k e^{-a_k^T \lambda}$

由此可得, 原问题等价于 $\min_{\lambda} (-b^T \lambda - \log \sum_{k=1}^n y_k e^{-a_k^T \lambda})$, 此即 $\min_{\lambda} (b^T \lambda + \log \sum_{k=1}^n y_k e^{-a_k^T \lambda})$, 证毕。